

CLASSIFICAÇÃO DE TUMOR CEREBRAL PETUITÁRIO, MENIGLIOMA E GLIOMA UTILIZANDO MULTI LAYER PERCEPTRON

HEINRYCH MATHEUS GOMES ANDRADE¹

PEDRO RAMOS KRAUZE DIEHL²

RUI GONÇALVES DE OLIVEIRA JÚNIOR³

¹UFG – Universidade Federal de Goiás

Escola de Engenharia Elétrica, Mecânica e de Computação - EMC/UFG

Setor Leste Universitário, Goiânia - GO, 74605-010

heinrych@discente.ufg.br

²UFG – Universidade Federal de Goiás

Escola de Engenharia Elétrica, Mecânica e de Computação - EMC/UFG

Setor Leste Universitário, Goiânia - GO, 74605-010

pedrodiehl@ufg.br

³UFG – Universidade Federal de Goiás

Escola de Engenharia Elétrica, Mecânica e de Computação - EMC/UFG

Setor Leste Universitário, Goiânia - GO, 74605-010

ruioliveira@discente.ufg.br

Resumo: Este artigo propõe um classificador com o escopo na detecção de três tipos de tumores cerebrais: tumores pituitários, meningiomas e gliomas, utilizando o recurso Multilayer Perceptron (MLP). Foram utilizados 2870 exames de ressonância nuclear magnética do crânio com suas respectivas classificações quanto a presença ou não de tumor, assim como o seu determinado tipo com o objetivo de formar um dataset de treino e validação para a rede neural. Em princípio, os resultados empenham uma taxa de acerto de 92,47% em classificação de tipos de tumor.

Palavras Chaves: tumor cerebral, multi layer perceptron, classificação.

1 Introdução

Tumores são definidos por um aumento em volume de partes dos corpos de seres vivos por uma multiplicação celular desregulada. Especificamente em tumores cerebrais, em seres humanos, há uma grande preocupação quanto a detecção e

tratamento dessa doença antes do aparecimento de complicações severas, principalmente por se tratar de uma região sensível e crucial para a vida do indivíduo. Essa doença atinge todas as faixas etárias e representam mais de 85% de todos os tumores primários do Sistema Nervoso Central (SNC), tendo uma média de

diagnóstico de cerca de 11.700 pessoas por ano. Um complicador importante está relacionado ao panorama de variedade de tamanhos, localização e natureza de tumores, o que pode gerar dificuldades na detecção, situação que pode ser resolvida com a utilização de tecnologias recentes de rede neural como o Multilayer Perceptron (MLP), para a facilitar a constatação de tumores em exames de ressonância nuclear magnética, que é justamente o foco do presente trabalho.

2 Estudo de caso

Como estudo de caso, foi utilizado o dataset fornecido pelos tutores através da plataforma “Kaggle”. O conjunto contém imagens de ressonância magnética de tumores cerebrais, contendo quatro subconjuntos de dados (sem tumor, glioma, meningioma e tumor pituitário).

A pasta contendo os dados referentes ao treinamento da Inteligência Artificial (IA), é composta por: 395 imagens Normais (Label = 0), 826 imagens com Glioma (Label = 1), 822 imagens com Meningioma (Label = 2), 827 imagens com tumor

Pituitário (Label = 3), totalizando 2870 imagens.

3 Metodologia

3.1 Pré-processamento

3.1.1 Imagem Original




Figura 1- Imagem original

3.1.2 Corte de região

Nesta etapa do processamento, inicialmente utilizando a ferramenta OpenCV, foi realizada a identificação.

No primeiro momento, a imagem foi colocada em na escala cinza para facilitar o processamento, onde se converte cores RGB para cinza. Logo após é realizado um thresholding, permitindo segmentar a região contornada do resto da imagem. Para detectar os contornos, é chamada a função `cv2.findContours`. Por fim, encontram-se os pontos extremos (esquerda, direita, cima, baixo) e o corte

é realizado, dessa forma, a imagem central torna-se mais evidente.




Figura 2 - Imagem cortada

3.1.3 Equalização de Histograma

A equalização de histograma faz o mapeamento de uma distribuição de intensidade luminosa, com o objetivo de deixar os valores mais uniformes, melhorando a percepção de detalhes por toda a faixa. Funciona com o princípio de aumentar o range de intensidade, melhorando o contraste da imagem e consequentemente a sua visibilidade geral.




Figura 3 - Imagem cortada e equalizada

3.2 Geração de Features

Para a geração de features, foi utilizado o aplicativo Keras, que é um modelo de aprendizado com pesos previamente treinados.

Uma ResNet é uma CNN, uma rede neural artificial que faz o empilhamento de blocos residuais uns sobre os outros com o objetivo de consolidar uma rede.

A rede neural escolhida foi o ResNet50, que é uma rede convolucional com 50 camadas de profundidade, sendo 48 camadas de convolução em conjunto de uma MaxPool e uma AveragePool.

Em primeiro momento é carregada uma versão pré-treinada da rede, que foi alimentada com milhares de imagens do banco de dados ImageNet. Sendo essa rede capaz de classificar imagens em 1000 classes.

A primeira cada convolucional é feita de tamanho de kernel 7x7 x 64, seguida por outras 47 no mesmo formato. Em sequência o AveragePool é aplicado, onde a maioria das camadas ocultas fazem uso da normalização seguida de uma camada de convolução.

A saída é uma camada totalmente conectada ou fully connected (FC) com 1000 recursos de saída para 1000 classes. Para corrigir esse “problema”, o modelo é ajustado, substituindo a camada FC por um novo conjunto de camada, para ter um out-features de 2048. Tal saída será a entrada do modelo.

3.3 Padronização utilizando o StandardScaler

O método StandardScaler foi utilizado para padronizar as 2048 features obtidas

pela ResNet50, tornando o valor do desvio padrão da distribuição igual a 1.

A equação que rege a conversão dos dados é representada da seguinte forma:

$$z = \frac{x-u}{s}$$

Onde **u** representa a média das amostras de teste e **s** representa o desvio padrão dessas mesmas amostras




Figura 4 - Features antes da padronização




Figura 5 - Features depois da padronização

Utilizando os padronizados, a precisão final aumentou em certa medida

3.4 Escolha do Modelo

Foi utilizado o GridSearch do SKLearn para encontrar os melhores hiper parâmetros da MLP.

Por limitações de processamento os parâmetros foram variados aos poucos e

entre essas variações foi fixado os melhores parâmetros.

Esse processo foi repetido algumas vezes até ser encontrado a versão final utilizada no projeto.

Portanto, os hiper parâmetros propostos para solução desse problema estão na Figura X. Como a arquitetura dos neurônios não foi passado como argumento, temos apenas uma camada escondida com 100 neurônios.

```
MLPClassifier(  
    activation='relu',  
    solver='adam',  
    random_state= 42,  
    max_iter=300,  
    alpha=0.01,  
    beta_1=0.7,  
    beta_2=0.999,  
    epsilon=5e-05,  
    early_stopping=False,  
    verbose=True,  
    tol=1e-5,  
    n_iter_no_change=13,  
)
```

Figura 6 - Hiper parâmetros MLP

Além disso, para o treinamento da rede foi utilizado uma split de 70% treino e 30% teste com embaralhamento, conforme a Figura 5. Antes da split os dados foram separados por classe e posteriormente foram agregados novamente de forma a garantir que todas as classes estejam presentes no treino e teste.




Figura 7 - Split treino e teste

4 Resultados

Ao realizar a classificação usando o MLP obtivemos um score com os dados de validação de 92.47% como mostra a Figura 6.

	precision	recall	f1-score	support
0	0.94	0.91	0.92	119
1	0.94	0.92	0.93	248
2	0.88	0.89	0.89	247
3	0.95	0.97	0.96	249
accuracy			0.92	863
macro avg	0.93	0.92	0.92	863
weighted avg	0.92	0.92	0.92	863

MLP Conjunto de teste score: 92.47%

Figura 6 – Score




Figura 7- Gráfico loss

Conforme a Figura 7, o modelo apresenta um resultado satisfatório na classificação dos 3 tipos de tumores, apresentado melhor resultado

na classe 3 (Pituitário) e pior resultado com a classe 2 (Meningioma).




Figura 8 - Matriz de confusão

No entanto, é importante ressaltar que a região de falsos negativos é a que mais se destaca podendo ser um problema relevante quando aplicado em situações reais, onde, a maior confusão ocorreu entre glioma e meningioma, verificando as imagens do dataset, estas apresentaram grande semelhança. Por fim, para fins de estudo o modelo de forma geral apresenta bons resultados.

5 Referências Bibliográficas

Md. Belal Hossain, S.M. Hasan Sazzad Iqbal, Md. Monirul Islam, Md. Nasim Akhtar, Iqbal H. Sarker, Transfer learning with fine-tuned deep CNN ResNet50 model for classifying COVID-19 from chest X-ray images, Informatics in Medicine Unlocked, Volume 30, 2022, 100916, ISSN 2352-9148.

CLOUDINARY. Cropping Images in Python With Pillow and OpenCV. Cloudinary, 2022. Disponível em: <<https://cloudinary.com/guides/automatic-image-cropping/cropping-images-in-python-with-pillow-and-opencv>> . Acessado em: 17/07/2022

VISUALIZATION OF MLP WEIGHTS ON MNIST. Scikit-learn, 2022. Disponível em: <https://scikit-learn.org/stable/auto_examples/neural_networks/plot_mnist_filters.html>. Acessado: 01/07/2022.

MLPCLASSIFIER. Scikit-learn, 2022. Disponível em <https://scikit-learn.org/stable/modules/generated/sklearn.neural_network.MLPClassifier.html> . Acesso dia: 17/07/2022